

# Relatório - Compiladores

Luan Bodner do Rosário

27 de Abril de 2016

## Introdução

Este documento tem como objetivo especificar o processo de implementação da primeira parte de um compilador(análise léxica e análise sintática) para a disciplina de Compiladores. Para a implementação do programa, foi utilizada a linguagem de programação C++ e a biblioteca *boost* para auxiliar na varredura do arquivo.

As saídas e entradas desse programa estão armazenadas em arquivos dados prévia à execução do compilador. O restante deste documento está organizado da seguinte forma:

- Análise Léxica : Funcionamento da varredura do arquivo e descrição das bibliotecas utilizadas e criadas para a captura das marcas do arquivo T++.
- Análise Sintática: Descrição do método utilizado para criação da AST ,análise da estrutura dos *tokens* e métodos de tratamento de erros.
- Gramática : Definição da gramática BNF utilizada para a criação da análise sintática e descrição da classe de tratamento de erros do compilador.

## Análise Léxica

Para o processo de varredura, não foi utilizada nenhuma ferramenta auxiliar para a construção da lista de *tokens*. Para que as marcas fossem reconhecidas no arquivo, foi utilizada a biblioteca *boost/regex*.

Os tipos de marcas foram armazenadas em um *enum* na biblioteca *Token.h*. Essa lista de marcas são definidas dessa forma:

```
typedef enum {  
    IF, THEN, OTHERWISE, END, REPEAT,  
    FLOAT, VOID, UNTIL, READ, WRITE,  
    INTEGER, COMMENTS, RETURN, SUM, SUBTRACTION,
```

```
MULTIPLICATION, DIVISION, EQUAL, COMMA, ATTRIBUTION,
LESS_THAN, BIGGER_THAN, LESS_EQUAL, BIGGER_EQUAL, OPEN,
CLOSE, NUMBER_INTEGER, NUMBER_FLOAT, DOUBLE_POINT, IDENTIFIER
} TokenType;
```

Quando dado *token* é analisado, o seu conteúdo é armazenado em um vetor de estruturas *tokens*

Os *tokens* são analisados de acordo com expressões regulares. As mais importantes listadas a seguir:

- `^\\b[A-Za-z _][A-Za-z _ 0 -9_]*`

```
static std::vector<Token::Token> tokens;
```

A classe *Token.h* é dada pela seguinte estrutura:

```
std::string tokenName;
TokenType token;
int tokenColumn;
int tokenLine;
```

O arquivo em que o código fonte é armazenado é lido linha por linha até que todos os caracteres sejam analisados e aceitos pela varredura, caso algum erro aconteça, a execução é finalizada. A varredura do arquivo é feita pela classe *LexicalAnalyzer*.

## Análise Sintática

A análise sintática deste projeto foi feita utilizando algoritmos *top-down* de análise recursiva descendente sem auxílio de ferramentas para a verificação da estrutura do programa.

A gramática BNF foi transformada para se adequar à análise descendente (retirada da recursão à esquerda).

Utilizando o algoritmo de descida recursiva, a gramática e a estrutura do programa ficaram bastante semelhantes, já que cada não terminal da gramática se tornou um método dentro do programa que avançava na lista de *tokens* conforme a leitura avançava.

A biblioteca responsável pela criação da árvore e análise é chamada de *SyntaxAnalyzer.h* e conta com apenas dois atributos:

```
Lex::LexicalAnalyzer lexer;
Tree::Tree syntaxTree;
```

A análise léxica está portanto diretamente ligada a análise sintática e não existirá sem uma instância da análise sintática, assim como a classe *Tree.h*, que é definida pela seguinte estrutura:

```
std::string exp;
Token::Token token;
int active;
std::vector<Tree*> children;
```

Conforme os *tokens* são analisados e se encaixam na gramática, eles também são inseridos na árvore de acordo com a sua colocação dentro do programa e sua necessidade. Desta forma, montamos uma árvore abstrata onde apenas as folhas representam valores diretamente do programa.

Os erros gerados durante a execução do programa foram especificados na classe *CompilerErrors.h* (tanto erros léxicos quanto erros sintáticos), onde cada método mostra uma mensagem adequada quanto a coluna e a linha do programa onde determinado erro aconteceu. Como por exemplo:

```
void CompilerErrors::unidentifiedTokenError(int Token, Token::Token token) {

    std::cout << "Unidentified_Token_Error;_"
                << "Received_:_"
                << intToString(Token)
                << ";_Expected_:_"
                << token.tokenTypeToString()
                << ";_Name_:_" << token.getTokenName();

    exit(EXIT_FAILURE);
}
```

Portanto, a cada erro encontrado, o programa mostra a mensagem de erro e é finalizado, o que gera o problema de não conseguir mostrar mais de um erro por compilação.

## Gramática

<type> ::= 'vazio'  
           | 'inteiro'  
           | 'flutuante'

<variableDec> ::= <type> ':' 'id'

<operationsExp> ::= <equalityExp>

<equalityExp> ::= <relationalExp> <equalityExpTransformed>

<equalityExpTransformed> ::= NULL  
                               | '=' <relationalExp> <equalityExpTransformed>

<relationalExp> ::= <additiveExp> <relationalExpTransformed>

<relationalExpTransformed> ::= NULL  
                               | < <additiveExp> <relationalExpTransformed>  
                               | > <additiveExp> <relationalExpTransformed>  
                               | <= <additiveExp> <relationalExpTransformed>

$$| \geq \langle \text{additiveExp} \rangle \langle \text{relationalExpTransformed} \rangle$$

$$\langle \text{additiveExp} \rangle ::= \langle \text{multiplicativeExp} \rangle \langle \text{additiveExpTransformed} \rangle$$

$$\begin{aligned} \langle \text{additiveExpTransformed} \rangle ::= & \text{NULL} \\ & | + \langle \text{multiplicativeExp} \rangle \langle \text{additiveExpTransformed} \rangle \\ & | - \langle \text{multiplicativeExp} \rangle \langle \text{additiveExpTransformed} \rangle \end{aligned}$$

$$\langle \text{multiplicativeExp} \rangle ::= \langle \text{factor} \rangle \langle \text{multiplicationExpTransformed} \rangle$$

$$\begin{aligned} \langle \text{multiplicationExpTransformed} \rangle ::= & \text{NULL} \\ & | * \langle \text{factor} \rangle \langle \text{multiplicationExpTransformed} \rangle \\ & | / \langle \text{factor} \rangle \langle \text{multiplicationExpTransformed} \rangle \end{aligned}$$

$$\begin{aligned} \langle \text{factor} \rangle ::= & '(\langle \text{operationsExp} \rangle)' \\ & | \text{'numberFloat'} \\ & | \text{'numberInt'} \\ & | \text{'id'} \end{aligned}$$

$$\langle \text{prototypeDef} \rangle ::= '(\langle \text{paramFunction} \rangle)'$$

$$\begin{aligned} \langle \text{paramFunction} \rangle ::= & \text{NULL} \\ & | \langle \text{variableDec} \rangle ', ' \langle \text{paramFunction} \rangle \\ & | \langle \text{variableDec} \rangle \end{aligned}$$

$$\langle \text{functionDec} \rangle ::= \langle \text{type} \rangle \text{'id'} \langle \text{prototypeDef} \rangle \langle \text{compoundStmt} \rangle \text{'fim'}$$

$$\begin{aligned} \langle \text{prototypeCall} \rangle ::= & \text{NULL} \\ & | \langle \text{operationsExp} \rangle ', ' \langle \text{prototypeCall} \rangle \\ & | \langle \text{operationsExp} \rangle \end{aligned}$$

$$\langle \text{functionCall} \rangle ::= \text{'id'} '(\langle \text{paramCall} \rangle)'$$

$$\langle \text{iterationExp} \rangle ::= \text{'repita'} \langle \text{compoundStmt} \rangle \text{'até'} \langle \text{operationsExp} \rangle \text{'fim'}$$

$$\begin{aligned} \langle \text{selectionExp} \rangle ::= & \text{'se'} \langle \text{operationsExp} \rangle \text{'então'} \langle \text{compoundStmt} \rangle \text{'fim'} \\ & | \text{'se'} \langle \text{operationsExp} \rangle \text{'então'} \langle \text{compoundStmt} \rangle \text{'senão'} \end{aligned}$$

$$\langle \text{compoundStmt} \rangle \text{'fim'}$$

$$\begin{aligned} \langle \text{ioTypes} \rangle ::= & \text{'id'} \\ & | \text{'numberInt'} \\ & | \text{'numberFloat'} \end{aligned}$$

| <functionCall>

<attributionExp> ::= 'id' ':' <operationsExp>

<returnCom> ::= 'retorna' '(' <operationsExp> ')'

<readCom> ::= 'leia' '(' 'id' ')'

<writeCom> ::= 'escreve' '(' <operationsExp> ')'

<compoundStmt> ::= <expression> <compoundStmt>  
| <expression>

<expression> ::= <selectionExp>  
| <iterationExp>  
| <functionCall>  
| <readCom>  
| <writeCom>  
| <returnCom>  
| <variableDec>  
| <attributionExp>